고급 프로젝트 보고서

코드잇 AI 엔지니어 12기
임현진

요약

뽀스팅은 혼자 카페를 운영하는 소상공인이 상품 사진과 간단한 정보만으로 가게 분위기에 맞는 Instagram 홍보물을 만들 수 있게 돕는 웹 서비스다. 문구는 gpt-5.4-mini, 이미지는 gpt-image-2을 사용한다. 모델은 바로 올릴 수 있는 홍보물 한 건을 얻는 데 드는 비용으로 비교해 골랐다. 확정한 모델로 한 건을 만드는 데 약 $0.013이 들고, 실제 앱에서 제작을 시작해 첫 결과를 받기까지 중앙값 43.4초가 걸렸다. 평가는 체크리스트 판정, 이미지 지표, LLM 판정으로 진행하였다.

1. 서론

1-1. 프로젝트 개요

뽀스팅은 혼자 카페나 베이커리를 운영하는 소상공인을 위한 Instagram 콘텐츠 제작 서비스다. 소상공인 광고 콘텐츠 생성이라는 과제 안에서 카페와 베이커리가 매일 반복하는 홍보 작업에 집중했다. 상품 사진과 기본 정보를 넣으면 저장해 둔 가게 스타일에 맞춰 문구와 이미지를 만들고, 확인한 뒤 게시까지 이어서 할 수 있다. 상품 홍보물 말고도 오늘의 라인업과 품절 공지를 만들 수 있고, 당일 예약 게시, 과거 게시물 반응 조회, 주기 브리핑 기능을 사용할 수 있다.

서비스 계획서 개인 개발일지

1-2. 배경

Instagram으로 두쫀쿠나 버터떡, 과일 모찌를 파는 카페 정보를 자주 찾아봤다. 카페 계정에는 거의 매일 상품 사진과 당일 라인업이 올라왔다. 혼자 매장을 운영하면서 이런 게시물까지 꾸준히 관리하려면 벅차겠다는 생각이 들었다.

손님이 몰리는 시간에는 결제와 제조, 상품 전달만으로도 손이 부족할 것 같았다. 홍보에 쓸 사진을 찍고 글을 올릴 시간을 따로 내기 어렵고, 상품이 바뀔 때마다 사진작가를 부르기도 부담스럽다. 그렇다고 게시물을 올리지 않으면 가게를 알릴 방법이 줄어든다.

그러던 중 AI로 상품 이미지를 다시 만들어 올리는 카페를 봤다. 상품 사진 한 장으로 홍보물을 만들고 게시까지 클릭 몇 번으로 끝낼 수 있다면 도움이 되겠다고 생각했고, 가게 분위기에 맞는 문구와 이미지를 한곳에서 만드는 서비스를 기획했다.

1-3. 평가 기준

사용자에게 필요한 건 생성 요청 한 번이 아니라 바로 올릴 수 있는 홍보물 한 건이다. 부록의 체크리스트를 모두 통과한 결과만 합격이고, 미충족과 부분 충족은 불합격으로 보았다.

지표	계산	뜻
합격률	합격 수 ÷ 시도 수	체크리스트를 모두 통과한 비율
기대 시도 수	1 ÷ 합격률	쓸 수 있는 결과 1건을 얻기까지 평균 생성 횟수
합격 1건당 비용	전체 비용 ÷ 합격 수	불합격한 시도 비용까지 넣은 원가
기대 대기 시간	API 중앙값 × 기대 시도 수	쓸 수 있는 결과 1건까지 기다리는 시간

지표	계산	뜻
제작 시간	앱이 브라우저에서 잰 시간	사람이 화면을 조작한 시간까지 넣은 시간

각 평가 지표가 서비스의 어떠한 부분을 설명하는지 정리한 표를 아래에 제시한다.

대상	묻는 것	근거	결과
연구자	왜 이 모델인가, 얼마나 드나	합격 1건당 비용, 기대 대기 시간	3-2
연구자	그 합격 판정을 믿을 수 있나	판정기와 사람 판정의 일치율	3-4
사용자	내 상품이 망가지지 않나	상품 영역 DINO 유사도	3-3
사용자	우리 가게 피드 같아 보이나	기존 피드와의 스타일 거리, 문구 말투	3-3, 3-6
사용자	시간이 얼마나 드나	실제 앱 제작 시간	3-5
소비자(손님)	이 홍보물이 끌리나	200명 블라인드 설문	미진행

1-4. 서비스 구성

FastAPI가 브라우저 요청을 받고 Jinja2로 HTML 화면을 만든다. CSS와 JavaScript, 글꼴도 같은 앱에서 내려준다. SQLite에는 상품과 가게 스타일, 제작권, 생성·게시 상태, 반응과 비용을 기록하고, 사진 원본과 후보, 완성본은 파일로 저장한다. 이미지는 Pillow로 렌더링한다. OpenAI와 Instagram에는 HTTP로 연결하고, 예약 게시와 반응 수집, 브리핑은 앱 안의 두 작업 흐름에서 처리한다.

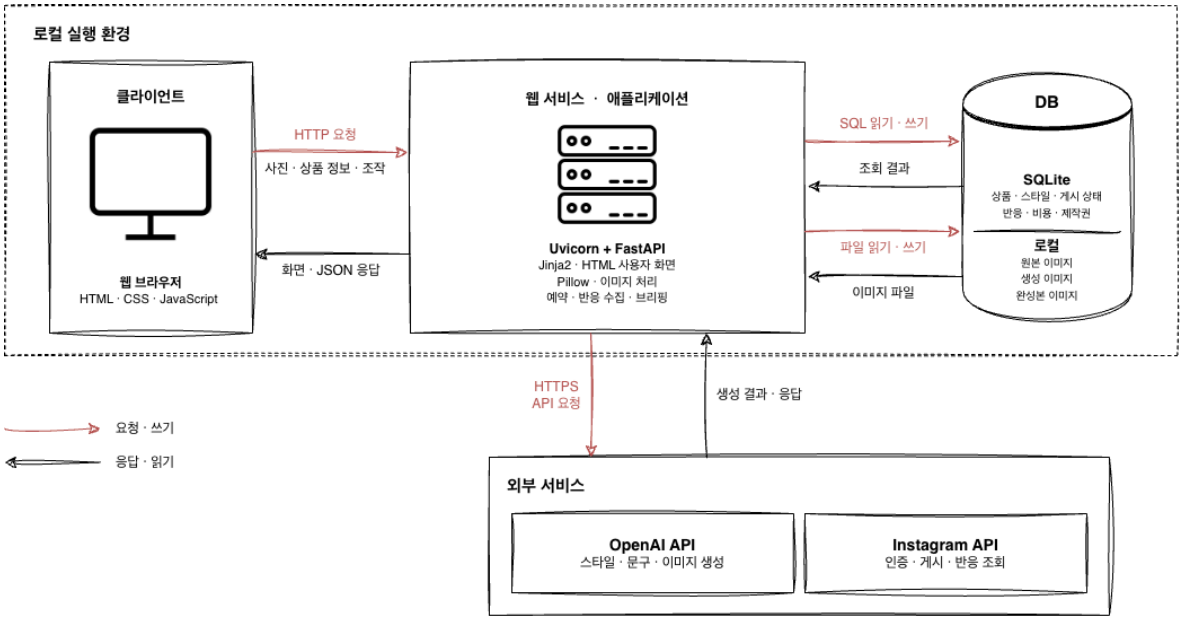


그림 1. 로컬 실행 구조. 브라우저와 FastAPI 앱, SQLite·파일 저장소는 한 PC에서 동작하고, 외부 AI와 Instagram API는 httpx로 HTTPS 호출한다.

구분	기술	역할
서버	Python 3.12 이상, FastAPI, Uvicorn	요청 처리, 기능 제공
화면	Jinja2, HTML, CSS, JavaScript	화면 렌더링, 사용자 조작
저장	SQLite, 로컬 파일	상태·버전·비용·반응, 이미지 보관
이미지 후처리	Pillow	미리보기, 완성본 렌더링
외부 통신	httpx	OpenAI, Instagram API 호출

구분	기술	역할
인증·보호	OAuth 상태, 세션, CSRF, Fernet	요청 검증, 연결 토큰 암호화

서버, 모델 호출, DB, 평가 도구는 `backend/`에, 화면은 `frontend/`에 있고, 운영 DB와 사용자 파일은 `data/`에 저장한다. 설치와 실행 기준은 `pyproject.toml`, `backend/main.py`, `backend/config.py` 을 참고하길 바란다.

화면은 Streamlit 대신 Jinja2로 만들었다. 이번 프로젝트에서는 모델을 직접 올리거나 서빙하지 않고 FastAPI로 서비스를 만들었다. 화면과 API를 한 앱에서 내려주면 명령 하나로 실행할 수 있어 설치도 짧다. 따라서 Streamlit보다 Jinja2가 이번 프로젝트에 적합하다고 판단하였다.

Instagram을 연결하면 기존 게시물과 캡션, 반응(Insight)을 가져와 저장하고, 스타일 제안과 반응 조회에 쓴다. 반응을 비교할 때는 목적이 같고 게시 후 경과 시간이 비슷한 일반 홍보 피드만 사용한다. 스토리와 라인업 게시물은 빼고, 값이 없는 경우와 반응이 0인 경우를 구분하였다. 비교 창은 게시 후 24±2시간으로 정했고, 정기 수집은 게시물당 한 번 시도한다.

무료 완성본 5건과 AI 호출 한도는 따로 측정한다. 제작권은 처음 확정할 때만 사용하고, 같은 게시물을 다시 확정하거나 다운로드, 게시를 다시 시도할 때는 차감하지 않는다. *제작권 추가 구매는 미구현 상태*

2. 본론: 실험 방법

2-1. 이미지 생성 방식 고르기

이미지로 생성된 상품은 원본과 같아 보여야 한다는 것을 기준으로 하였다. 처음에는 상품 영역을 지정해 그 부분을 지키고 배경만 새로 만드는 방식을 썼고, 다음에는 SlimSAM으로 상품을 오려 내 새 배경에 붙였다. 해 보니 사장님이 영역을 지정하고 경계를 고치는 일이 늘었고, 결과도 오려 붙인 티가 나거나 상품 모양이 변했다. 두 방식을 같이 쓰는 단계를 거쳐, 결국 오려 내는 단계를 없애고 원본 사진 전체를 이미지 모델이 자동으로 편집하는 방식으로 정했다. 아래는 같은 원본 사진으로 만든 두 결과다.

SlimSAM 누끼·합성 방식



그림 2-1. 같은 원본 사진을 SlimSAM으로 오려 합성한 결과

GPT 이미지 자동 편집 방식



그림 2-2. 같은 원본 사진을 GPT 이미지 모델로 자동 편집한 결과

2-2. 모델 비교 실험

문구, 이미지, 스타일 분석에 쓸 모델을 고르기 위해 두 번의 비교 실험을 진행하였다. 같은 입력과 같은 설정으로 후보마다 한 번씩 생성하고, 생성 중에는 프롬프트와 설정, 비용을 바꾸지 않았다. 자세한 실험 조건은 아래의 부록을 참고하길 바란다.

자료	구성	쓰임
상품 사진	원본 1장과 각도·조명을 바꾼 합성 4장	후보마다 같은 5장 입력
상품	가게의 새 상품 1개(스푸키 쿠키)	가운데 메인 쿠키 1개를 남겨야 함
스타일 참고	기존 Instagram 사진과 캡션 8개	두 분석 모델에 같은 자료로 입력
평가자	본인	개별 품질, 묶음 일관성, 선호 판정

첫 번째 실험은 문구 모델 2개(gpt-5.4-mini, gpt-5.4)와 이미지 모델 2개(gpt-image-1-mini, gpt-image-2)를 사진 5장에 돌려 결과 20개를 만들었다. 두 번째 실험은 기존 게시물 8개로 스타일 분석 모델 2개를 한 번씩 돌리고, 문구와 이미지 모델은 고정한 채 같은 사진 5장으로 문구 5개, 이미지 5개씩 만들었다. 분석 2회와 후속 생성 20개다. 처음에는 상품 사진으로 스타일을 분석하는 탐색 실험도 했는데, 실제로는 기존 게시물로 스타일을 정하므로 선정 근거에서 제외하였다.

결과는 문구 9개 기준(T01~T09), 이미지 4개 기준(H01~H04)으로 하나씩 판정했다. 같은 조건의 결과 5개는 나란히 놓고 말투나 색감이 일관된지 따로 봤고, 어느 쪽이 더 나은지도 골랐다. 검토 화면에서는 모델 이름과 비용을 가리고 순서를 섞었다. 부분 충족, 미충족, 선호에는 모두 이유를 적었다. 비용은 API 사용량으로 계산한 추정치이며, 시간은 API 응답 시간의 중앙값이다.

평가 계획·실험 결과

2-3. 이미지 지표

체크리스트로 보면 이미지 20개가 모두 상품 보존(H01) 충족이었다. 합격과 불합격만으로는 모델 차이가 보이지 않아서, 비슷한 과제를 선행 연구의 지표로 비교 실험을 진행했다. 생성 편집은 배경을 새로 그리므로 이미지 전체의 정답은 없다. 하지만 상품은 원본과 같아야 하므로 메인 쿠키 영역만 잘라 원본과 비교했다. 상품 영역 박스는 입력 5장과 결과 20장에 손으로 지정했다.

보는 것	지표	고른 이유
상품 보존	상품 영역 DINO(ViT-S/16) 코사인 유사도	DreamBooth에서 주제 충실도 지표로 썼다. 같은 종류 안의 개체 차이를 CLIP보다 잘 구분하고 사람 선호와의 상관도 더 높았다고 한다(DINO 0.32, CLIP-I 0.27). Malhi et al. 2025처럼 상품 영역만 잘라 계산했다.
가게 스타일	VGG-16 Gram 행렬 스타일 거리	스타일 전이(Gatys et al.)에서 쓰는 스타일 표현이다. 기존 게시물 8장과의 평균 거리를 잰다.
쓸 수 있는 비율	합격률	광고 이미지 생성 논문 Du et al. (ECCV 2024)도 사용 가능 비율(availability rate)을 주 지표로 쓴다.

2-4. LLM 판정

사람 판정 체크리스트를 수정하거나 재실험을 진행하기 어려웠다. 그래서 같은 체크리스트를 판정기로 옮기고, 먼저 내 판정과 얼마나 맞는지 확인했다. 날짜(T03), 제품명으로 시작(T05), 문단 수(T06), 필수 태그(T08), 태그 수와 중복(T09)은 코드로 판정했다. 할로윈 연결(T02), 입력에 없는 사실(T04), 말투(T07), 이미지 기준(H01~H04)은 gpt-5.4에 입력 사진과 결과를 같이 보여 주고 기준마다 판정과 이유를 받았다. 같은 판정을 두 번 돌려 판정기가 스스로 일관된지도 봤다. 참고한 VIEScore (ACL 2024)에서는 GPT-4o 판정과 사람의 상관이 0.4로 사람끼리의 상관 0.45와 비슷했다. 판정 모델이 생성 모델과 같은 GPT 계열이라 자기 결과를 좋게 볼 수 있다는 점은 감안하였다.

2-5. 정성 평가

이번 정성 평가는 연구자 혼자 블라인드로 판정하였다. 정성 평가가 의미를 가지기 위해서는 200명 정도의 평가가 필요하다(해당 부분은 강사님과 의논한 내용을 발취한 것). 하지만 이번 프로젝트에서는 진행하기 어려웠다. 따라서 다음의 내용은 200명의 평가자에게 평가를 진행할 경우를 가정하고 내린 결정이다. 200명 규모라면 손님 입장에서 광고가 끌리는지, AI 티가 나는지, 가 보고 싶은지를 블라인드 쌍 비교로 묻는 게 맞다고 본다. 200명이면 선호 비율의 95% 신뢰구간이 약 ±7%p가 된다. 사용자(소상공인) 입장의 사용성은 3~5명 사용성 테스트로 볼 수 있다.

2-6. 반복 사용 실측

비교 실험에 쓰지 않은 상품 사진 5장(초콜릿 라떼, 핸드드립, 차이티, 시나몬롤, 빅토리아 케이크)을 실제 앱에서 직접 만들었다. 앱은 제작 시작, 문구 미리보기, 이미지 후보 표시, 수정 후 미리보기 시점을 브라우저에서 기록하였다. 로컬에서 측정하기 위해 Instagram 계정을 연동하지 않고, 저장된 스타일과 참고 게시물을 측정용 계정에 복사해서 스타일의 일관성을 맞추었다.

2-7. 문구 말투 수정

2-6에서 만든 문구를 읽어 보니 기존 피드와 말투가 달랐다. 기존 게시물 8개와 생성 문구 5개를 해시태그 줄을 빼고 줄 단위로 세어 봤다.

	기존 피드	생성 문구
마침표로 끝나는 줄	0% (36줄 중 0줄)	63% (19줄 중 12줄)
"~입니다/습니다"로 끝나는 줄	6%	37%
이모지가 있는 줄	28%	16%

시나몬롤 문구에는 입력하지 않은 "부드럽고 진한 풍미"가 들어갔고, "~로 소개드립니다" 같은 마무리도 반복됐다. 기존 게시물은 이미 예시로 같이 보내고 있었지만, 지시문이 말투를 참고하라는 정도여서 마침표 같은 습관은 따라가지 않았다. 그래서 기존 게시물에서 마침표, 격식체, 이모지 비율을 코드로 세어 규칙 문장으로 넣었다. 입력에 없는 맛, 식감, 온도 표현과 어느 상품에나 붙는 마무리도 금지했다.

말투 교정 후, 5개 상품으로 고치기 전과 후의 문구를 두 번씩 다시 만들었다. 마침표, 격식체, 이모지 비율과 입력에 없는 감각 표현 수를 셌고, 상품마다 전후 문구 한 쌍을 순서를 섞어 놓고 내가 더 나은 쪽을 골랐다.

3. 결론

3-1. 최종 구현

상품 홍보물을 만들고 원본과 비교해 수정, 확정, 다운로드하는 흐름을 완성했다. 가게 스타일 제안, 라인업과 품절 공지, 예약, 과거 반응 조회, 브리핑에서 다음 초안으로 이어지는 기능도 붙였다. 공개 서버는 두지 않았다. 임시 공개 주소를 계속 유지하고 Instagram 설정을 바꾸는 부담과 비용 때문에, 로컬 실행 방법과 시연 영상으로 대체했다. 영상에는 연결 상태와 스타일 저장부터 문구·이미지 생성, 원본 비교, 라인업·품절 스토리 게시, 브리핑과 반응 조회까지 담았다.

시연 영상

3-2. 모델 선정 결과

스타일 분석과 문구에는 gpt-5.4-mini, 이미지에는 gpt-image-2를 골랐다.

구분	모델	합격	5건 비용(USD)	문구 API 중앙값(초)
문구	gpt-5.4-mini	5/5	0.011951	2.153
문구	gpt-5.4	5/5	0.041664	4.318
이미지	gpt-image-1-mini	3/5	0.037250	-
이미지	gpt-image-2	5/5	0.054210	-

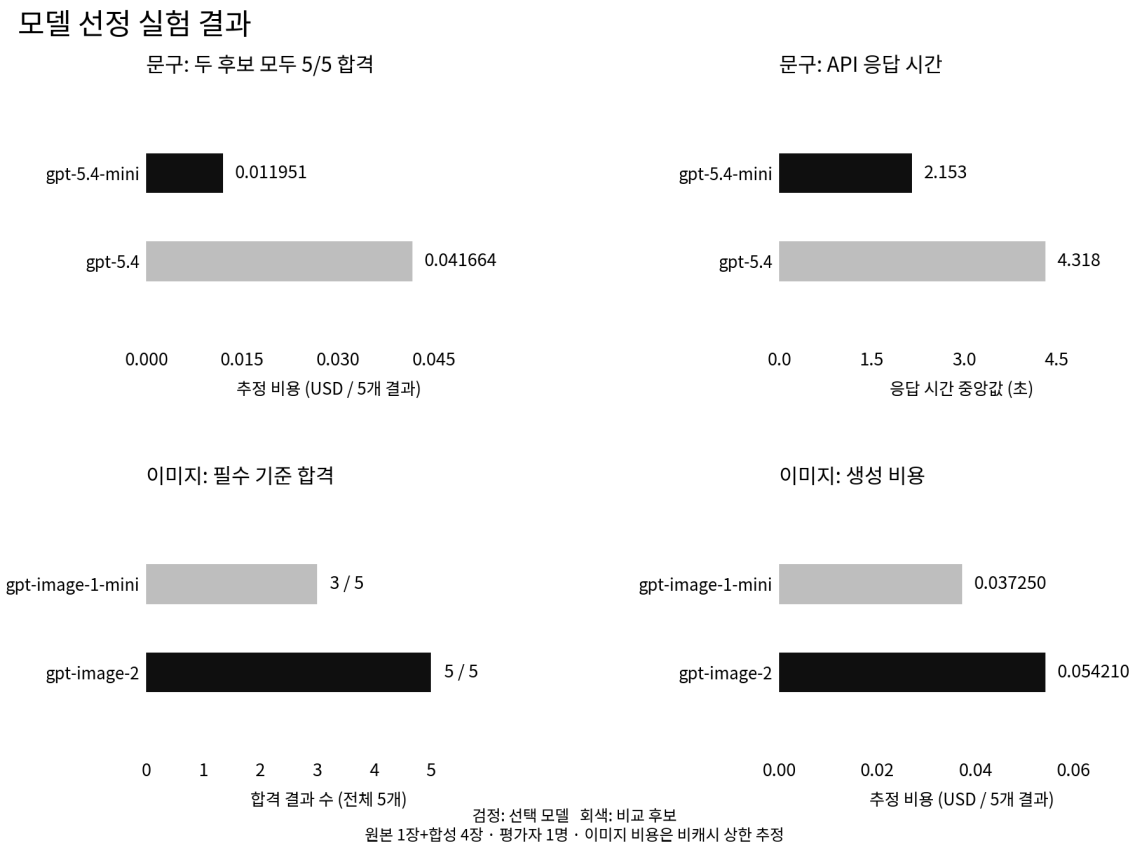


그림 3. 모델별 합격 수, 추정 비용, 문구 API 응답 시간. 비용은 5건 합계, 시간은 중앙값이다.

문구는 두 모델 모두 5/5였다. 블라인드 선호에서는 mini를 선택하였으며, gpt-5.4 문구에는 같은 단어를 세 번 넘게 쓴 글이 많았다는 문제점을 발견하였다. mini가 비용은 71%, 응답 시간은 50% 적었다.

이미지는 처음에 더 싼 gpt-image-1-mini가 비용적 측면에서 적합하리라 생각했다. 1회 생성 비용은 gpt-image-2가 45.5% 비쌌지만, 불합격한 뒤 재생성 비용까지 넣으니 결과가 반대였다.

이미지 모델	합격	1회 비용(USD)	합격 1건당 비용(USD)	기대 시도 수	기대 대기(초)
gpt-image-1-mini	3/5	0.007450	0.012417	1.67	18.3
gpt-image-2	5/5	0.010842	0.010842	1.00	13.4

gpt-image-2가 합격 1건당 비용은 12.7% 낮고 기대 대기 시간은 27% 짧았다. gpt-image-1-mini가 떨어진 2건은 모두 최종 4:5 미리보기에서 쿠키 양 끝이 잘린 경우(H04)였다.

지표	mini 분석 경로	gpt-5.4 분석 경로
후속 문구 합격	5/5	3/5
후속 이미지 합격	5/5	5/5
기존 피드 일치	충족	충족
문구 묶음 일관성	충족	부분 충족
스타일 분석 1회 비용(USD)	0.010185	0.035000
스타일 분석 API 시간(초)	5.849	16.922
분석+후속 생성 비용(USD)	0.078127	0.104589

스타일 분석도 mini로 채택하였다. 분석 비용은 71%, 시간은 65% 적었고 후속 문구도 더 많이 통과했다. 다만 gpt-5.4 경로에서 떨어진 문구 2건은 태그 개수는 맞았지만 본문과 태그 칸에 같은 해시태그가 두 번 나와 불합격 처리한 경우였다. 이 문제는 앱에서 본문과 태그의 중복을 정리하도록 고쳤다.

3-3. 이미지 지표 결과

조건	상품 DINO↑ (범위)	피드 스타일 거리↓
gpt-image-1-mini	0.753 (0.71~0.79)	0.727
gpt-image-2	0.894 (0.84~0.91)	0.696
스타일 분석 mini 경로	0.879 (0.82~0.91)	0.692
스타일 분석 gpt-5.4 경로	0.869 (0.83~0.92)	0.698
입력 사진(기준선)	-	1.463

DINO 값은 gpt-image-1-mini 5장이 전부 gpt-image-2의 5장보다 낮았다. 이미지를 다시 보면 mini 쪽은 유령 장식이 커지고 눈 모양이 바뀌어 있는데, 체크리스트로 볼 때는 이걸 불합격으로 치지 않았다. 피드 스타일 거리는 결과 이미지가 0.69~0.73, 입력 사진이 1.463으로, 어두운 할로윈 원본이 가게 피드의 밝은 우드톤 쪽으로 약 52% 가까워졌다. 스타일 분석 모델 두 경로는 이미지 지표 차이가 거의 없었고, 차이는 문구에서 드러났다.

3-4. LLM 판정 결과

실험	내 판정과 일치율	Cohen's κ	두 번 돌렸을 때 같은 비율
모델 비교(120개 판정)	89.2%	-0.03	100%
스타일 분석 경로(120개 판정)	90.8%	0.25	97.1%

코드로 판정한 날짜, 제품명, 태그 기준은 연구자의 판정과 모두 동일하였고, 해시태그 중복 2건도 그대로 잡았다. 문단 수는 본문이 한 문단으로 나온 1건에서 어긋났다. κ가 0 근처인 건 연구자의 판정이 거의 다 "충족"이라 값에 변화가 없기 때문이다. 이럴 때는 일치율이 높아도 κ가 낮게 나와서 둘을 같이 봐야 한다. 미리보기에서 잘린 2건은 LLM이 인지하지 못하였다.

판정 방식	gpt-image-1-mini	gpt-image-2	두 모델이 갈렸나
사람 체크리스트	5/5 충족	5/5 충족	아니오, 모두 합격
LLM 판정	5/5 부분 충족	5/5 부분 충족	아니오, 모두 불합격
DINO	0.71~0.79	0.84~0.91	예, 범위가 겹치지 않음

상품 보존은 내가 20장 모두 "충족", LLM은 20장 모두 "부분 충족"으로 매겼다. LLM의 부분 충족 이유는 "눈·입 비율과 유령 형태가 원본과 다르다"였다. 세 단계로 매기는 판정은 사람은 보다 너그러웠으며, LLM은

엄격하였으며, 두 평가 모두 두 모델을 구분하지 못했다.

3-5. 반복 사용 실측 결과

구간	중앙값	범위
제작 시작부터 첫 AI 후보까지	43.4초	31.9~66.6초
그중 사람 조작	17.7초	11.5~52.4초
이미지 생성 버튼부터 후보 표시까지	14.2초	14.2~28.3초
제작 시작부터 문구 미리보기까지	3.1초	2.6~4.9초
수정 요청부터 미리보기 갱신까지	0.2초	0.2초

5건 비용은 합계 $0.071, 1건에 약 $0.014였다. 처음 측정한 사용 실측 1건(83.1초)보다 짧았지만, 앱을 만든 연구자 본인이 쟀으니, 처음 쓰는 사용자보다는 빨랐을 것이라 생각된다. 비교 실험 10건에서 잰 API 시간(문구 약 2초, 이미지 약 13초)을 더하면 사진 1장당 AI 대기는 약 15초로, 기획 때 정한 목표와 일치하였다.

3-6. 문구 개선 결과

조건	문구 수	마침표로 끝나는 줄	격식체 끝	이모지 줄	입력에 없는 감각 표현
기존 피드	8	0%	6%	28%	-
고치기 전	10	63%	21%	16%	15건
고친 후	10	0%	0%	5%	5건

감각 표현은 정해 둔 단어 목록으로 측정하였다. "따뜻한 커피랑 같이"처럼 함께 마실 음료를 말한 경우도 걸리므로, 고친 후 5건에는 잘못 측정된 값도 섞여 있다고 할 수 있다.

상품	고른 쪽	이유
초콜릿 라떼	고치기 전	초콜릿이 중심이라는 점을 더 잘 살렸다
핸드드립	고치기 전	고친 후의 "담아두었어요"가 어색했다
빅토리아 케이크	고치기 전	케이크 설명과 한정 메뉴라는 점이 잘 드러났다
시나몬롤	고친 후	고치기 전의 "겉은 고소하고 안쪽은 달콤"은 지어낸 내용이었다. 고친 후는 메뉴 이름 옆 이모지가 빠졌다
차이티	고친 후	"한국에서도 즐기실 수 있게 준비했어요"가 작성자의 의도를 잘 살렸다

수치는 좋아졌으나, 블라인드로 고른 건 5개 중 2개였다. 마침표와 지어낸 맛 표현은 줄었지만, 초콜릿이나 한정 판매처럼 상품의 핵심이 약해졌고 메뉴 이름 옆 이모지도 빠졌다. 표면 규칙을 세는 지표만으로는 "가게 글 같다"는 판단을 대신할 수 없었다.

하지만 앱에는 수정된 문구 규칙을 남겼다. 지어낸 맛 표현을 막는 쪽이 사실 확인 기준(T04)에서 더 중요하다고 생각하였기 때문이다.

3-7. 한계

- 모델 비교는 한 가게, 한 상품(원본 1장과 합성 4장)으로 했다. 같은 입력을 여러 번 생성했을 때의 안정성이나 다른 카페, 다른 상품에서의 결과는 확인하지 못했다.
- 사람 판정은 모두 연구자 본인이 진행했다. LLM 판정의 기준이 된 정답도 내 판정이고, 판정 모델이 생성 모델과 같은 GPT 계열이다.

- 반복 사용 실측과 문구 재측정은 상품 5개다. 문구는 문제를 찾은 상품으로 다시 평가했고, 마침표 유무로 전후가 쉽게 구분돼 완전한 블라인드는 아니었다.
- 상품 영역 박스를 손으로 지정해서 박스를 조금 다르게 잡으면 지표 값도 조금 달라진다.
- 실제 카페 사장님의 사용성은 재지 못했다. 예약 시각의 실제 게시와 오래 운영했을 때의 동작도 시험하지 못했다.
- 반응 분석과 브리핑은 테스트 계정이라 실제 반응 데이터가 부족했다.

3-8. 회고

가장 아쉬운 건 무엇을 기준으로 판단할지 정하기 전에 기능부터 만들었다는 점이다. 좋은 모델이나 많이 쓰는 API를 연결하면 결과도 좋을 거라고 생각했다. 그래서 상품을 지키는 방식을 5일 동안 세 번 바꿨다. 상품 모양만 보고, 그 대가로 사장님 손이 더 가는 걸 비용으로 보지 않았다.

기획할 때 평가를 놓친 데는 이유가 있었다. 가이드라인이 서비스 완성도를 강조해서, 평가도 만든 기능이 기준을 통과하는지 보는 검사처럼 짰다. 모델 결과의 품질과 서비스가 주는 가치를 따로 잴 생각은 하지 못했다. 모델을 직접 학습하지 않고 API만 쓰니 PSNR, SSIM 같은 지표는 연구용이라고 여겼고, 배경을 새로 그리는 서비스라 정답이 없다고만 생각해서 상품 부분은 원본과 비교할 수 있다는 걸 늦게 알았다. 평가 규모도 내가 혼자 볼 수 있는 20개에 맞췄다. 판정을 자동화해 양을 늘리거나 내 판정이 믿을 만한지 확인한다는 생각은 하지 못했고, 누구를 설득할지도 정하지 않아 10월 26일부터 29일 사이에 평가 목적이 세 번 바뀌었다.

후반에 부분 충족도 불합격으로 보는 기준과 합격 1건당 비용이라는 지표를 세우고 나서야 판단에 근거가 생겼다. 단가만 보면 gpt-image-1-mini가 합리적이었지만 다시 만드는 비용까지 넣으면 gpt-image-2가 더 싸고 빨랐다. 실험에서 찾은 해시태그 중복은 앱 수정으로 이어졌다. 반대로 문구 말투는 숫자를 맞추는 것만으로는 부족하다는 것도 직접 확인했다.

다시 한다면 작은 기능부터 만들고, 필요한 비교를 먼저 하겠다. 무엇을 보여 줄 프로젝트인지 정한 뒤 선택지와 결과를 기록하면서 기능을 늘려 갈 생각이다. 오픈소스 모델이나 더 낮은 단계의 직접 구현도 해 보고 싶다.

부록

- 서비스 계획서
- 평가 계획·실험 결과
- 개인 개발일지

A. 비교 실험의 고정 조건

항목	고정 조건
상품·판매 정보	codeit의 스푸키쿠키(쿠키). 10월 26일~11월 6일 할로윈 한정 판매. 확인하지 않은 가격·재료·식감·제조 방식은 추가하지 않는다. 흰 장식의 실제 재료도 사진만으로 확정하지 않는다
입력	`cafenew3.jpg` 원본 1장과 촬영 조건을 모사한 합성 4장. 모델별로 같은 5장을 한 번씩 처리. 한 가게·한 상품·평가자 1명이다
가게·스타일	대구광역시 OO동 카페·아인슈페너와 구움과자 소개. OO동은 임시 표기다. 우드·브라운·베이지·크림/화이트, 따뜻하고 부드러운 자연광 또는 은은한 실내 광원, 정돈된 배경과 음식 중심 구도. 메뉴 고유색을 유지한다
배경·구도	우드 테이블·아이보리 벽·크림색 식기·패브릭·트레이 중 어울리는 요소를 사용한다. 가까운 음식 사진 또는 테이블 정물, 상단·사선 구도, 중앙 또는 약간 비대칭 배치와 여백을 허용한다. 모든 소품이나 검정·보라색 할로윈 배경을 요구하지 않는다

항목	고정 조건
상품 보존	큰 원형 스탠드 앞줄 오른쪽, 화면 중앙에 가까운 메인 쿠키 1개만 남긴다. 나머지 쿠키는 제거한다. 갈색의 둥근 형태·표면 질감, 흰 유령 장식·짙은 눈과 입·대략적인 비율·장식과 쿠키의 연결 구조를 보존한다. 각 합성 입력에서도 같은 개체를 사용한다
생성 설정	최종 비교의 문구는 reasoning `none`·최대 2048토큰·표준 처리 등급, 이미지는 `low`·1024×1024. 최종 비교 중 프롬프트·설정·단가를 임의 변경하지 않는다
최종 출력	피드 미리보기 4:5·1080×1350. 생성 원본과 최종 미리보기를 모두 보관한다. 새 문구·날짜·로고를 삽입하지 않는다. 포인트 색 #76472e의 정확한 픽셀 출현은 요구하지 않는다
스타일 분석 비교	같은 기존 게시물 사진·캡션 8개의 순서와 해시를 고정한다. 두 모델로 각각 새로 분석하고 후속 문구 mini·이미지 Image 2를 동일하게 유지한다. 이전 확정 분석은 입력 대신 감사 기록으로 보존한다

B. 판정 기준

기준	판정 기준
T01	본문에 스푸키쿠키와 쿠키 종류가 드러난다
T02	본문에 할로윈과 연결되는 내용이 있다. 특정 문장 복사는 요구하지 않는다
T03	10월 26일~11월 6일의 양쪽 날짜와 한정 판매 조건이 모두 정확하다
T04	제목·본문·해시태그에 미제공 가격·재료·식감·제조 방식을 사실처럼 추가하지 않는다
T05	본문이 제품명으로 시작한다. 평가 제외인 이모지와 공백은 첫 실제 내용 판정에서 무시한다
T06	본문은 2~4개 짧은 문단이다. 끝의 해시태그 묶음은 본문 문단 수에서 제외한다
T07	부드러운 존댓말을 사용한다
T08	`#할로윈 #카페 #대구카페 #쿠키`가 모두 포함된다
T09	위 태그 외 추가는 최대 2개다. 중복을 제외한 전체 태그는 4~6개다. 중복 노출 문제는 고유 개수와 구분해 기록한다. 기존 판정은 소급 변경하지 않는다
H01	상품 보존: 선택한 메인 쿠키와 같은 상품으로 보이는가. 상품 수는 1개인가
H02	스타일 적합성: 따뜻한 색감·조명·정돈된 배경이 반영됐는가
H03	자연스러움: 상품과 배경의 경계·그림자·접촉면에 이상이 없는가
H04	최종 미리보기: 1080×1350이며 메인 상품·장식이 잘리지 않고 새 문구가 삽입되지 않았는가

C. 판정 기록 파일

- 개별 평가 `reviews.csv`: 문구 10행(T01~T09)과 이미지 10행(H01~H04), 세부 판정 130개. 부분 충족과 미충족은 결과마다 문제가 있는 기준과 이유를 적는다.
- 묶음 평가 `bundles.csv`: 같은 모델·스타일로 만든 결과 5개를 나란히 놓고 문구의 말투·문장 길이·설명 방식, 이미지의 색감·조명·배경이 일관된지 판정한다. 문구 A/B와 이미지 A/B의 4행이고, 스타일 분석 비교에서는 기존 피드와 맞는지도 따로 본다.
- 선호 평가 `preferences.csv`: 문구와 이미지 각 1행에 A 우세, 비슷함, B 우세와 이유를 적는다. 평가자 표기는 `evaluator.txt`에 둔다.
- 재현에 쓰는 명령: `python -m backend.kpi_report`(합격 1건당 비용), `python -m backend.eval_metrics`(이미지 지표), `python -m backend.eval_judge`(규칙·LLM 판정), `python -m backend.caption_retest`(문구 재측정)